UNIVERSITÉ DU QUÉBEC EN OUTAOUAIS

Département d'informatique

Dashboard d'estimation du risque de crédit basé sur des modèles à base d'arbres

Plan de travail

Projet de synthèse (INF4173)

Présenté à
Ekwelle Epalle Thomas Martial

par

Mohamed Aliou Diallo

Ablavi Emefa Doumenyo

Baccalauréat en informatique

Science des données et intelligence artificielle

Gatineau

8 février 2026

Table des matières

1. Introduction 2
2. Problématique 3
3. Objectifs du projet 3
4. Développement 4
    4.1 Cadre théorique et revue de littérature 4
    4.1.1 Risque de crédit et défaut de paiement 4
    4.1.2 Modélisation du risque de crédit 4
    4.1.3 Rôle des variables macroéconomiques 4
    4.2 Données et variables 4
    4.2.1 Données microéconomiques 4
    4.2.2 Données macroéconomiques 4
    4.2.3 Variable cible et variables indépendantes 5
5. Méthodologie 5
    5.1 Prétraitement des données 5
    5.2 Analyse exploratoire 5
    5.3 Modélisation du taux de chômage (ARIMA) 5
    5.4 Modélisation du défaut de paiement 5
    5.6 Intégration micro–macroéconomique 6
    5.7 Évaluation des modèles et choix du meilleur modèle 6
6. Application démonstrative 6
7. Planification et gestion du projet 6
8. Conclusion 7

1. Introduction

La prédiction du risque de défaut de paiement constitue un enjeu majeur pour les institutions financières. Les défauts de paiement entraînent des pertes importantes et nécessitent des mécanismes de prévention basés sur des modèles statistiques et d'apprentissage automatique.

Ce projet de synthèse vise à développer un **dashboard prédictif** permettant d'estimer la probabilité de défaut d'un client en combinant :

- des **données microéconomiques** (caractéristiques individuelles des clients),
- un **indicateur macroéconomique** (taux de chômage au Canada).

L'objectif est d'évaluer l'apport des variables macroéconomiques dans la prédiction du risque de crédit et de comparer différents modèles de classification, notamment ceux basés sur les arbres de décision.

Ce plan de travail présente le cadre théorique, les données utilisées, la méthodologie scientifique, la planification du projet ainsi que les résultats attendus.

2. Problématique

Les institutions financières doivent anticiper le risque de défaut de paiement afin de réduire leurs pertes et d'améliorer la gestion du crédit. Cependant, les comportements individuels des clients et les conditions macroéconomiques rendent la prédiction du défaut complexe.

Ce projet cherche à répondre à la question suivante: **comment combiner données microéconomiques des clients et les indicateurs macroéconomiques pour prédire efficacement le risque de défaut de paiement?**

3. Objectifs du projet

- Réaliser une analyse statistique descriptives des profils clients.
- Visualiser les comportements de défaut de paiement et les tendances macroéconomiques.
- Étudier l'évolution du taux de chômage à l'aide du modèle de séries temporelles ARIMA.
- Développer des modèles de classification (régression logistique ou Random Forest, xgboost) pour prédire le défaut de paiement.
- Comparer les performances des modèles et discuter leur pertinence dans un contexte canadien.

4. Développement

4.1 Cadre théorique et revue de littérature

4.1.1 Risque de crédit et défaut de paiement

La littérature définit le risque de crédit comme la probabilité qu'un emprunteur ne respecte pas ses obligations financières. Les facteurs déterminants incluent l'historique de crédit, l'historique de paiement, le niveau d'endettement et les caractéristiques sociodémographiques.démographiques.-démographiques.

4.1.2 Modélisation du risque de crédit

Les modèles classiques incluent la régression logistique, tandis que les modèles modernes basés sur les arbres offrent une meilleure capacité à capturer des relations non linéaires. L'étude de Yeh & Lien (2009) démontre l'efficacité des modèles avancés sur le dataset UCI.

4.1.3 Rôle des variables macroéconomiques

Les conditions économiques influencent la capacité des ménages à rembourser leurs dettes. Le taux de chômage est un indicateur clé, souvent corrélé à l'augmentation des défauts de paiement. La littérature recommande d'intégrer ces variables pour améliorer la robustesse des modèles.

4.2 Données et variables

4.2.1 Données microéconomiques

Dataset : *Default of Credit Card Clients* (UCI Repository)

- Pays : Taïwan
- Période : avril–septembre 2005
- 30 000 clients
- Variables sociodémographiques, financières et comportementales-démographiques, financières et comportementales
- Historique de paiement sur 6 mois
- Montants facturés et montants payés

4.2.2 Données macroéconomiques

Source : Banque mondiale (WDI)

- Indicateur : taux de chômage (% population active)
- Période : 1960–2023

- Pays : Canada
- Utilisation : analyse ARIMA + intégration dans le dashboard

4.2.3 Variable cible et variables indépendantes

- **Variable cible** : défaut de paiement (0 = non, 1 = oui)
- **Variables indépendantes** : X1 à X23 + taux de chômage

5. Méthodologie

5.1 Prétraitement des données

- Nettoyage
- Normalisation
- Encodage
- Fusion micro/macro

5.2 Analyse exploratoire

- Statistiques descriptives
- Visualisations (corrélations, distributions)

5.3 Modélisation du taux de chômage (ARIMA)

- Analyse temporelle
- Prévision
- Intégration dans le dashboard

5.4 Modélisation du défaut de paiement

- Régression logistique
- Random Forest
- XGBoost

Ces modèles ont été retenus en raison de leur performance reconnue dans la littérature pour les problèmes de classification binaire et de risque de crédit.

5.6 Intégration micro–macroéconomique

- Ajout du taux de chômage comme variable explicative
- Comparaison des modèles avec/sans macro

5.7 Évaluation des modèles et choix du meilleur modèle

- Accuracy
- Precision
- Recall
- F1-score
- Matrice de confusion

6. Application démonstrative

Une application simple sera développée sous forme de **dashboard interactif** permettant :

- d'entrer les caractéristiques d'un client,
- d'ajuster le taux de chômage,
- d'obtenir une estimation du risque de défaut,
- de visualiser l'importance des variables.

Technologies possibles : Streamlit, Dash ou une interface web légère.

7. Planification et gestion du projet

Le projet s'appuie sur des sources de données fiables,ainsi que sur une revue de littérature en science des données et apprentissage automatique. Les outils techniques utilisés incluent Python, Jupyter Notebook, Pandas, NumPy, Scikitlearn, Statsmodels, Matplotlib et Seaborn. La gestion du projet est assurée via GitHub (issues, branches, Kanban) selon une approche inspirée de la méthodologie Agile Scrum. Les livrables attendus sont : le plan de travail, le rapport de progrès, le rapport final, la vidéo de démonstration et la documentation du travail réalisé.-learn

Dates	**Activités**	**Livrables**
1–14 février	Revue de littérature + collecte	Section littérature
15–28 février	Prétraitement + EDA	Graphiques, tableaux

Dates	Activités	Livrables
1–14 mars	ARIMA	Notebook ARIMA
15–28 mars	Modèles ML	Modèles entraînés
29 mars – 11 avril	Comparaison + interprétation	Résultats
12–25 avril	Dashboard	Application
26 avril – 10 mai	Rapport final + vidéo	Rapport PDF, démo

8. Conclusion

Ce plan de travail présente une démarche scientifique rigoureuse visant à modéliser le risque de défaut de paiement en intégrant des données microéconomiques et macroéconomiques.

Le projet devrait aboutir à une analyse statistique et économique complète du risque de crédit, à la construction et l'évaluation de modèles prédictifs, ainsi qu'à la mise en place d'une application démonstrative permettant de visualiser les résultats. Le rapport final présentera l'ensemble de la démarche scientifique, les résultats obtenus et les limites du projet.